10월 19일 작업 정리

IAA AI-Assisted Hackathon 2026 · 지우진, Krista Stanke · Part 1 마감 10월 23일(금)

> **오늘 한 줄 요약.** 처음으로 Kaggle에 제출했고, 공개 점수를 **0.11803 → 0.11973**(채택 모델 v7)까지 올렸어요. 그 과정에서 타깃 정의 오류를 바로잡고, 사고 이력이라는 강한 신호를 찾았고, 모든 결정을 **결과를 보기 전에 정한 규칙**으로 내렸어요. 마지막에는 motor 과소 예측의 유력한 원인(BI 심도 추세)을 찾았어요.

0. 먼저 큰 그림: 우리가 하는 일

대회는 **2025년 계약 하나하나의 최종 청구 비용(기대값)**을 예측하라고 해요. 공제금액과 회수금을 빼고, 거절된 청구는 제외한 금액이에요. 사업비나 이익은 넣지 않은 **순수 위험 보험료**예요.

우리 모델은 두 단계로 돼 있어요.

- **1단계, 타깃 만들기:** 2021~2024년 청구를 2025년 수준으로 맞춰요(심도 추세, BI 제도 변화, 빈도 수준 이동). 아직 덜 보고된 최근 연도는 가중치를 낮추고, 아주 큰 청구는 상한에서 잘라 따로 처리해요.
- **2단계, 라인별 모델:** 계약의 특성(운전자 나이, 지역, 날씨, 과거 사고 등)으로 노출당 요율을 예측하고, 2025년 노출을 곱해요.

> **점수(D^2)를 읽는 법.** 계약 한 건의 손해는 대부분 운이라(대부분 0원, 가끔 큰 금액), 완벽한 모델도 D^2가 0.1 안팎이에요. 상위 10팀이 0.125~0.130이에요. 0.001 차이는 잡음일 수 있어요.

1. 점수 흐름

버전	바뀐 것	공개 점수	쉽게 말하면
v2	규제 GLM, 균형 보정	0.11803	첫 제출. 다만 공제금액 정의가 틀린 상태
B	모든 담보에 공제금액 적용	0.11724	정의를 바로잡았는데 점수는 떨어짐(motor 수준이 낮아져서)
v3	신호 없는 변수 제외	0.11798	쓸데없는 변수를 빼니 회복
v4	과거 사고 이력 추가	0.11907	오늘 가장 확실한 개선
v5	contents에 GLM + GBM 결합	0.11996	규칙을 통과한 첫 GBM
v6	큰 손해 loading을 꼬리 분포로, 변수 정리	0.11951	계리적으로 더 타당하지만 점수는 조금 하락(예측 첫 실패)
v7 (채택)	**contents를 더 잘 규제한 GBM(씨앗 3개 평균)**	**0.11973**	**현재 최종 후보**
결합 v1 / v2	실험용(채택 안 함)	0.12113 / 0.12186	점수는 높지만 가장 안전한 고객을 과대 예측

2. 오늘 한 일, 하나씩

각 항목은 왜 발견 결정 순서로 정리했어요.

① 규제(ridge)와 균형 보정

왜 기준 모델이 가장 안전한 계약을 약 20% 과소 예측했어요. 상대도가 너무 가팔랐던 거예요.

발견 상대도를 평균 쪽으로 당기는 규제를 주니 해결됐어요. 그런데 당기면 전체 금액도 같이 줄어요(예: 2배와 0.5배를 1.4배와 0.7배로 당기면 합계가 250 → 212). 그래서 학습 데이터로 정한 계수 k 하나를 곱해 전체 수준을 다시 맞췄어요. **활쏘기에 비유하면**, 규제는 화살을 모으는 것이고 k는 조준기를 맞추는 거예요.

결정 motor α0.5 · 구간 10, buildings α0.5 · 구간 20, contents α0.3 · 구간 20. 검증 D^2: 0.050→0.051, 0.055→0.065, 0.060→0.067.

② 공제금액 정의 (주최 측 확인)

왜 배상 책임 담보(BI, 제3자 재물)에 공제금액을 빼는지 데이터로는 알 수 없었어요. AI가 영국 관행을 근거로 "빼지 않는다"고 가정했어요.

발견 주최 측이 포럼에서 "모든 담보에 적용"이라고 답했어요. **그런데 리더보드는 틀린 정의를 0.0008 더 높게 평가했어요.** 리더보드만 믿었다면 틀린 타깃을 골랐을 거예요.

결정 모든 담보에 적용. `target.py` 기본값 변경, 테스트 기대값 5개를 손으로 다시 계산.

③ 변수 점검: 안정성과 관련성

왜 GBM이 "이전 보험사"를 가장 중요한 변수로 꼽았는데 계리적으로 이상했어요(역선택 가설도 검토).

발견 이전 보험사별 손해율 순위가 2021~22년과 2023~24년 사이에 전혀 유지되지 않았어요(순위 상관 ≈ 0). 우연을 외운 거예요. 그리고 갱신 횟수 = 가입 연수(완전히 같은 정보), 나이 ≈ 면허 기간, 지역 ≈ 날씨, 직업 ≈ 나이라는 관계도 찾았어요.

결정 신호 없는 변수와 중복 변수를 뺐더니 GLM이 오히려 좋아졌어요(v3).

④ 과거 사고 이력 (오늘 가장 큰 발견)

왜 보험에서 미래 사고를 가장 잘 예측하는 건 과거 사고예요. 그런데 아직 쓰지 않고 있었어요.

발견 전년에 청구가 있던 계약은 **22~80% 과소 예측**되고 있었어요. 고객이 신고한 과거 사고(prior_claims_5y)는 실제 청구 기록과 거의 무관했어요(상관 0.04).

결정 "1월 1일 이전에 보고된 청구"로 이력 변수를 만들었어요. 2025년 테스트와 같은 기준이라 미래 정보가 섞이지 않아요. 알 수 없는 경우는 0이 아니라 '모름'으로 뒀어요(v4, +0.0011). 담보별 이력이나 과거 청구 **금액**은 효과가 없거나 미래 정보가 섞여서 쓰지 않았어요.

⑤ GBM(LightGBM) 시험

왜 상위권과의 차이(약 0.01)는 GLM이 못 잡는 상호작용일 수 있어요.

발견 buildings와 contents에서 검증 D^2 +0.007~0.011. 하지만 **가장 안전한 10% 계약을 30% 넘게 비싸게** 매겨요. 설정을 18가지로 바꾸고 보정까지 해 봐도 buildings는 고쳐지지 않았어요. motor는 이득이 거의 없어요.

결정 규칙(+0.003 이상, 양 끝 구간이 0.1 넘게 나빠지지 않을 것)을 통과한 **contents만** GBM 사용(v5 → v7). buildings는 목요일 팀 결정.

⑥ 큰 손해 loading: 사고 한 건의 문제

왜 "너무 큰 사고는 그냥 빼면 안 되나?"라는 질문에서 시작했어요.

발견 motor loading 16의 **96%가 1,189만짜리 BI 청구 한 건**(아직 진행 중)에서 나왔어요. 빼면 0.71이에요. 10만이 넘는 청구 119건으로 파레토 꼬리를 맞추니 $\alpha \approx 2$, loading 2.83으로 기준 금액을 바꿔도 안정적이었어요.

결정 loading 2.83을 위험에 비례해 배분(v6). 불확실성 범위 1.2~3.8을 기록. 통째로 빼지 않은 이유는 실제 손해와 점수 모두 큰 사고를 포함하기 때문이에요.

⑦ 기본 점검: 한도와 담보

발견 가입 금액을 넘는 청구는 0.02~0.03%. 특약 없이 지급된 우발적 손해 청구는 실제로 지급된 청구라 타깃에 그대로 둬야 해요.

결정 조치 필요 없음. 기록만.

⑧ BI 심도 추세 (마지막 발견, 내일 첫 작업)

왜 motor를 낮출 때마다 리더보드 점수가 떨어졌어요. motor가 실제보다 낮다는 신호예요.

발견 조건을 맞춰 비교하니 BI 심도가 제도 변화 후에도 해마다 **+7.7%(중앙값 +9.4%)** 올라요. 우리는 0%로 가정하고 있었어요. 그런데 추세만 바꾸면 2024년 검증이 나빠졌어요. 제도 변화 계수 0.83이 "추세 0%" 가정 아래 정한 값이라, 둘이 얽혀 있었어요.

결정 지금은 규칙대로 유지. 내일 추세 6%와 제도 계수 약 0.79를 **같이** 바꿔 검증해요.

3. 우리가 결정하는 방식

- **규칙을 먼저 정하고 결과를 봐요.** 예: "GBM은 GLM보다 D^2 +0.003 이상이고 양 끝 구간이 0.1 넘게 나빠지지 않을 때만 채택." 결과를 보고 기준을 바꾸면 결과에 맞추는 셈이라서요.
- **결정은 검증으로, 리더보드는 확인용으로.** 학습에 쓰지 않은 연도(2023, 2024)로 검증해요. 제출 전에 점수 변화를 미리 적었고, **7번 중 6번** 맞았어요. 틀린 한 번(v6)도 원인을 설명할 수 있었어요.
- **리더보드에 맞추지 않아요.** 공개 점수는 테스트 일부로만 계산돼서, 공개 점수가 높은 걸 고르면 최종(비공개) 순위에서 떨어질 수 있어요.

4. AI를 어떻게 검증했나 (오늘 예시)

AI가 한 것	결과
배상 책임 담보에는 공제금액이 없다는 가정	틀림 주최 측 답변으로 확인
빈도를 "순손해액 > 0" 청구로만 센 재확인	잘못된 경보 세 정의를 나란히 비교해 원래 계수 0.93 확인
동점 규칙 방향, 근거 없는 k 3% 상한, 4년 평균과 비교한 수준 점검	수정
과거 청구 금액을 변수로 쓰자는 제안	철회 금액에 미래 정보가 섞임
실행 시간 예측, v6 점수 예측	틀림 기록
균형 보정, 사고 이력, 꼬리 분포 loading, 리더보드 예측	확인 검증과 리더보드로

사람이 던진 질문도 방향을 바꿨어요. "균형 보정은 인위적이지 않나?", "역선택일 수 있지 않나?", "직업은 무엇에 영향을 주나?", "극단치를 빼면 안 되나?", "모델 전에 상관관계를 봤어야 하지 않나?"

5. 지금 모델 (v7)

라인	모델	특징
motor	규제 Tweedie GLM (구간 10)	사고 이력, 집 관련 변수 제외, 큰 손해 loading 2.83을 위험에 비례해 배분
buildings	규제 Tweedie GLM (구간 20)	사고 이력
contents	LightGBM (잎 7, 최소 5,000, L2 50, 씨앗 3개 평균)	사고 이력, GLM보다 검증 D^2 +0.0106

6. 가장 큰 남은 문제 세 가지

1. **motor 수준이 낮아요.** 손해의 56%라 점수 영향이 가장 커요. BI 추세와 제도 계수를 같이 고치는 게 첫 시도예요.
2. **buildings의 GBM 이득(+0.009)을 못 쓰고 있어요.** 점수와 공정한 보험료 사이의 선택이라 목요일 팀 결정이에요.
3. **재현 가능한 파이프라인이 없어요.** v7은 노트북 셀을 순서대로 돌려 만들었어요. 평가 20% 항목이고 2주차에도 꼭 필요해요.

7. 금요일까지 계획

날	할 일
화 (5시간)	BI 추세 + 제도 계수, **보고서 목차 초안 → Krista 공유**, contents GBM p=1.4, glass 추세, contents 2023
수 (3시간)	pipeline.py, 제출 전 점검 함수, GitHub 자동 테스트
목 (5시간)	최종 모델 확정, 파이프라인으로 다시 만들어 비교, GOVERNANCE.md, 진단 노트북, **저녁 7시 Krista와 줌**
금 (10/23)	최종 제출, 검증 기준으로 최종 평가용 2개 선택

8. 용어 정리

용어	뜻
A/E	실제 ÷ 예측. 1보다 크면 과소 예측, 작으면 과대 예측
D^2 (Tweedie, p=1.5)	평균 하나만 쓰는 모델보다 오차를 몇 % 줄였나. 대회 점수
최하위 / 최상위 구간	예측 위험이 가장 낮은 / 높은 10% 계약
GLM / GBM	변수별 상대도를 곱하는 모델 / 결정나무 수백 개를 더하는 모델
규제(ridge)	상대도를 평균 쪽으로 당겨 우연에 덜 휘둘리게 하는 장치
균형 보정 k	학습 데이터의 예측 합계를 실제 합계에 맞추는 계수
loading	상한에서 자른 큰 손해의 기대 비용을 다시 더해 주는 금액
완성도	사고 연도의 손해 중 지금까지 보고된 비율. 최근 연도일수록 낮음